VGHTC Queue Agent：以公開燈號資料預測門診叫號時間並主動提醒出門的領域智慧代理人

羅志緯（5115050039）　鄭博仁（5115050003）　張佳筑（5115050030）
國立中興大學　人工智慧學位學程
課程：人工智慧與資訊安全　指導教授：陳煥　期末專題提案（Proposal）　2026 年 11 月

摘要— 2025 年國人平均每人門診就醫 16.3 次、65 歲以上人口達 20.1%，大型醫院單一診次掛號上百號是常態。本專題對臺中榮總全院門診燈號的連續觀測顯示：各診間每叫一號的時間相差近 10 倍，單一下午全院有 89 次超過 20 分鐘的停滯，而現場已報到人數中位數僅為剩餘號碼數的 18%——等待時間取決於後面的人何時出現，不是號碼差。然而現有醫院 App 與第三方工具全以「號碼」提醒，不換算時間；學術預測研究則依賴病人拿不到的院內資料，也未處理「幾點出門」這個風險方向與「還要等多久」相反的決策。本專題提出 **VGHTC Queue Agent**：只用公開看診進度資料、從病人端建立的門診候診領域智慧代理人。系統由已全天候運行的燈號收集器、以醫師為單位的即時與歷史速率特徵、LightGBM 分位數回歸（P20/P50/P80）、編碼叫號規則與診次生命週期的領域知識層，以及確定性的監看—推理—決策迴圈組成，LLM 僅用於公告分類與解釋生成。評估以真實燈號資料回測，與滾動平均等基準線比較 MAE、分位數損失、覆蓋率，以及面向病人的過號率、空等分鐘與通知次數。預期產出臺中榮總門診叫號時間資料集、一個在過號率與空等時間上優於固定規則的分位數模型，以及一個不蒐集個資、可實際使用的 LINE 候診代理人。

關鍵詞—門診候診時間預測、排隊管理、分位數回歸、LightGBM、LLM Agent、LINE Bot

I. Introduction

A. Attention Getter

2025 年國人平均每人門診就醫 16.3 次 [12]，同年底 65 歲以上人口達 20.1%、正式進入超高齡社會 [13]，高齡者正是大型醫院門診最主要、也最難使用數位工具的族群。本專題自 2026 年 10 月 22 日起對臺中榮民總醫院（下稱臺中榮總）全院門診燈號每分鐘一次的觀測顯示：皮膚科單一診次最末號達 160；全院單一下午 5 小時內出現 89 次兩次叫號間隔超過 20 分鐘的停滯，最長 86 分鐘；各診間每叫一號的中位數為 3.2 分鐘，但最快與最慢相差近 10 倍（最快診間 1.0 分鐘，最慢為 CT 檢查室 9.3 分鐘）。同樣是「前面還有 10 號」，可能等 10 分鐘，也可能等一個多小時，而病人沒有工具分辨。

B. Background

臺中榮總官網提供每 60 秒刷新的即時看診進度（目前號、最末號、過號看診號、已報到待看診人數），官方 App 在掛號查詢中顯示「預估報到時間」[19]。門診叫號並非先到先服務：病人插健保卡報到後才會被叫，未報到的號碼被跳過，過號者重新報到後插回，高齡者優先——臺北榮總明文「每看 2 位正常號序後，先排 1 位 85 歲以上高齡長者，接續安插 1 位過號者」[14]，臺中榮總則公告 83 歲以上插卡後自動排序 [15]。診次有固定生命週期（上午 08:30、下午 13:30、夜診 18:00 開診，初診報到截止 11:30／16:30／19:30 [16]），請假、代診以診間公告發布。技術上，候診時間預測已從滾動平均發展到排隊理論與統計學習的混合模型 [1]、分位數回歸 [2]、以即時佇列狀態為核心的樹模型 [3, 4, 6] 與 conformal 校準 [9]；LLM agent 的架構與安全原則亦已成形 [10, 11]。

C. Problem

病人要的不是「現在看到幾號」，而是兩個決策：「**我的號碼幾點會被叫到？**」與「**我幾點該出門，才能不過號、也不空等？**」答案取決於即時狀態、醫師個別效應與叫號規則，而且會變——請假、速度變慢、長者與過號者插入都會讓半小時前的估計失效。因此需要的不是一次性預測，而是**持續監看、狀態改變時重新推理、在對的時間主動提醒**的系統。形式化地說：給定診間、午別與號碼 N，Agent 須在任一時刻輸出 N 的叫號時間區間與出門建議，並在事件發生時更新。

D. Existing Limitations

(1) **現有工具以號碼為單位**：臺北榮總的「前 5 號提醒」[20]、門診小幫手 [22]、全能掛號王 [21]、看診進度助手 [23] 皆為固定號碼差；臺中榮總 App 的「預估報到時間」是掛號時的靜態值，不隨進度更新也無推播 [19]。 (2) **學術模型依賴院內資料**：等待時間預測研究 [1, 2, 3, 4, 5, 6] 全用院內報到系統資料，結果不回到病人端；模型須分院訓練、跨機構遷移未解 [1, 3, 17]，但沒有人處理「只能外部觀測燈號」時如何學到醫師效應。 (3) **不確定性只處理一個方向**：文獻一致以非對稱損失或高分位數避免低估等待 [2, 3, 18]，但「幾點出門」晚了會過號，方向相反，無人研究。 (4) **LLM agent 集中在對話式預約** [11]，而綜述 [10] 指出 agent 在需持續追蹤情境的動態任務最弱。

E. Innovation

(1) **資料**：只用公開 API 自建每分鐘的全院燈號資料集，不碰個資；(2) **預測對象**：直接預測號碼 N 的叫號時間，以醫師為分析單位；(3) **不確定性與決策分離**：P50 附 P80 回答「等多久」，P20 決定「幾點出門」；(4) **Agent 而非模型**：確定性迴圈決定何時通知，領域知識層編碼叫號規則與公告語意，LLM 只做分類與解釋；(5) **病人端評估**：過號率、空等分鐘、通知次數。

F. Contributions

- **資料**：首個以公開燈號建立的臺中榮總門診叫號時間資料集，及跳號、停滯、醫師效應的量化描述。
- **方法**：從外部燈號序列學習醫師效應與叫號規則影響的特徵工程與分位數預測，以排隊式基準線為對照與退路。
- **系統**：可實際使用的 LINE 候診代理人，展示「監看—預測—推理—主動提醒」的 Domain AI Agent 設計。
- **評估與實務**：以病人決策為中心的指標，以及只用公開資料、對醫院零額外負擔、不蒐集個資的資安實作範例。

II. Related Work

A. AI Technology

1) 候診時間預測： 醫院公布等待時間的傳統做法是滾動平均，近十年的研究都以它為基準線：Ang 等人 [1] 以 Lasso 結合排隊理論的流體模型（Q-Lasso），Pak 等人 [2] 以排隊變數做 ML 並改用分位數回歸，兩者對滾動平均的改善主要來自修正低估。門診方面，Shin [3] 與 Guo [4] 以 SHAP 證明即時佇列長度是最強特徵、醫師效率次之，LightGBM 等樹模型穩定優於線性與深度模型（含 TabNet、FT-Transformer）；Wang [5] 以擁擠狀態預測急診是否久等；Liu 等人 [6] 以台灣亞東醫院資料預測抽血佇列長度。共同限制：全部依賴院內資料，且預測的是等待分鐘或佇列人數，不是個人的叫號時間。

2) 排隊理論 vs. 機器學習： Chocron 等人 [8] 在刻意違反標準假設的多類別系統上直接對決：排隊理論預測器常與 ML 相當甚至更好、成本低得多，ML 只在某類顧客具高優先權時勝出。Senderovich 等人 [7] 的 queue mining 則證明以排隊理論結構化事件日誌的預測器大幅優於忽略排隊結構的迴歸。榮總門診的正常號、過號者與長者正是三個優先權類別，燈號序列就是事件日誌。

3) 不確定性量化： 分位數回歸 [2] 與非對稱損失 [3] 的動機都是「低估比高估傷人」；Shahbazi 等人 [9] 以群組感知的 conformal 校準在階層醫療資料上達到接近目標的覆蓋率，並示範單用 Bayesian 不確定性會嚴重低覆蓋——區間的覆蓋率必須校準並報告。

4) LLM Agent： Chowa 等人 [10] 綜述 108 篇研究，指出 agent 在需持續追蹤情境的動態環境表現最弱；Hasan 等人 [11] 的醫療預約 agent 把緊急偵測與拒絕醫療建議做成確定性護欄而非交給 LLM。啟示：核心迴圈應為確定性程式，LLM 只做可驗證的事。

B. Domain Know-how：門診排隊管理

1) 叫號作業規則： 臺北榮總便民手冊 [14] 的「2 正常號 + 1 位 85 歲以上長者 + 1 位過號者」交錯規則、臺中榮總的 83 歲以上自動排序 [15]、開診與報到截止時間 [16]，直接導致**號碼差不等於等待時間**：未報到號碼被跳過（本專題觀測單步前進僅 55%）、長者與過號者從側邊插入、報到截止後不再有新病人。

2) 病人行為與等候心理： Toffaha 等人 [17] 回顧 52 篇未到（no-show）預測研究，指出未到行為依場域而異、跨機構遷移未解；對本專題而言，未到與遲到是跳號與停滯的來源。Zhang 等人 [18] 的情境實驗顯示告知的預期等待與實際差 10 分鐘內滿意度仍顯著提升，差 20 分鐘以上則無

效——應告知區間、寧可略高估、誤差超過 20 分鐘就失去意義。

3) 既有系統： 臺中榮總 App [19]（靜態預估報到時間）、臺北榮總 App [20]（前 5 號提醒）、全能掛號王 [21]、門診小幫手 [22]、看診進度助手 [23]：全部以號碼為單位，沒有時間換算、不確定性或狀態變化時的主動通知。

C. Summary and Research Gap

表 1 整理 12 篇核心文獻。**Existing Research**：樹模型＋即時佇列特徵、分位數與非對稱損失、conformal 校準、queue mining，以及叫號規則與病人心理的公開文件都已成熟。**Limitations**：全用院內資料且不回到病人端；預測對象非個人叫號時間，叫號規則的非線性未建模；不可跨院移植卻無人處理外部觀測；病人端工具只看號碼；agent 未用於持續監看與主動提醒。**Research Gap**：缺少只用公開燈號、從病人端建立、能學到醫師速度與叫號規則效果、以分位數表達不確定性、並以 agent 迴圈在狀態改變時重新推理的系統；台灣尚無以看診進度資料做預測的公開研究。**Our Project**：VGHTC Queue Agent 針對此缺口，自建資料集、以醫師為單位做分位數預測並校準覆蓋率、把叫號規則與公告語意編碼為領域知識、以確定性迴圈決定何時通知，並以病人端指標評估。

III. Deep Research

領域定位：門診候診時間預測與排隊管理（Healthcare Operations）。「本專題觀測」指 2026-10-22 下午 5 小時、5,310 筆燈號變化的初步分析。

A. 五個核心思維模式

1) 等待是系統狀態的函數，不是號碼的函數： Little’s Law [24]；Shin [3] 與 Guo [4] 的 SHAP 以佇列長度為首要特徵；本專題觀測現場人數中位數僅為剩餘號碼數的 18%。*設計*：輸入是即時狀態，Agent 必須持續監看，靜態的「預估報到時間」不成立。

2) 變異比平均更重要： Kingman 近似 [25]：等待隨變異膨脹。每號中位 3.2 分，但 5 小時內 89 次 ≥20 分鐘停滯；Ang [1] 與 Pak [2] 發現滾動平均的主要錯誤是低估。*設計*：輸出分位數；指標含覆蓋率與低估比例；停滯當事件偵測。

3) 服務速率跟著人走： 文獻模型一律單院或分院訓練 [1, 3, 4, 6]，跨機構遷移未解 [17]；本專題觀測各診間（含檢查室）每號 1.0–9.3 分。*設計*：分析單位是醫師；代診時退回基準線並告知信心下降；鎖定單一醫院是合理的。

4) 風險不對稱，方向取決於問題： 告知等待時低估比高估傷人 [3, 18]；「幾點出門」晚了會過號，方向相反。*設計*：「等多久」用 P50 附 P80；「幾點出門」用 P20；評估分別看低估比例與過號率。

5) 系統是開放的，人會對資訊反應： 病人會遲到、未到、過號再回來 [17]，醫院主動改變順序 [14]，告知資訊會改變行為 [18]——預測一旦公布，被預測的系統就變了。*設計*：規則與公告作為領域知識輸入；求可信區間與重新通知而非極致精度；監測漂移；收集使用者回報。

B. 三個最重要的專業爭論

1) 排隊理論 vs. 資料驅動 ML： A：排隊模型有解析解、小資料可用、能答反事實。B：真實門診違反所有假設，ML 更準。*證據*：Chocron [8] 直接對決——排隊理論常相當或更好，ML 只在有高優先權類別時勝出；Ang [1] 與 Guo [4] 以理論挑特徵、ML 建模。*共識*：混合。*未解*：小資料佇列、反事實。*本專題*：榮總門診正是有優先權的情境，但仍以「號碼差 × 速率」為基準線與退路；回測若 ML 贏不了基準線就用基準線。

2) 保守估計 vs. 準確估計： A：寧可讓病人以為要等久一點。B：系統性高估失去信任、把人困在醫院。*證據*：Shin [3] 非對稱損失減少低估但犧牲精度；Zhang [18] ±10 分有效、±20 分無效。*共識*：給區間，上界管理期望，覆蓋率要校準 [9]。*未解*：區間如何對長輩溝通；「幾點出門」的保守方向相反，文獻幾乎未研究——本專題的 P20 規則是自己的設計，要靠過號率與空等分鐘驗證。

3) 先到先服務 vs. 優先權插隊： A：嚴格依號碼最可預測，插隊可被策略性利用。B：高齡者為友善就醫對象 [14, 15]，$c\mu$ 規則 [26] 支持對等待成本高的類別給優先權。*證據*：北榮固定交錯規則；本專題觀測燈號幾乎不倒退，推論插隊是「插在下一個」（待驗證）；Chocron [8] 指出此情境 ML 有優勢。*共識*：有限度優先權，規則公開固定。*未解*：最佳交錯比例；外部看不到年齡時能否從燈號學到插隊效果。*本專題*：不建模年齡，

Table 1. Article Summary Table

Ref.	Year	Problem	AI Method	Domain Knowledge	Dataset	Findings	Limitation
[1] Ang et al., M&SOM	2016	急診低急迫病人等待時間	Q-Lasso（Lasso + 排隊流體模型）	急診分流、排隊理論	4 家美國醫院急診歷史資料	MSPE 比最佳滾動平均低 >30%，主要改善低估	急診場域；需院內資料
[2] Pak et al., IJMI	2021	急診候診室等待時間	ML + 分位數回歸	排隊與服務流程變數、日內波動	澳洲公立急診	MSPE 優於滾動平均 >20%；嚴重低估減少 42%；提議「低估比例」指標	低急迫病人；資料量未載明
[3] Shin et al., HCMS	2024	門診等待時間與病人不滿	LightGBM + TreeSHAP + 非對稱損失、DAES	佇列長度、醫師效率、時段	韓國大型醫院 2 科，約 1.1 萬 + 0.4 萬筆	非線性優於線性；佇列長度最重要；非對稱損失減少低估但犧牲精度	單院、4 個月；資料不公開
[4] Guo et al., JMIR Med Inform	2025	兒童醫院 13 種佇列等待	9 種 ML（RF/ XGBoost/ LightGBM 最佳）	排隊理論特徵：排隊人數、到達率	北京兒童醫院 230,864 筆	排隊人數首要；檢驗佇列 R^2 0.93	單院、冬季；小樣本佇列差
[5] Wang et al., BMC HSR	2025	急診等待是否 >30 分鐘	LR/RF/XGBoost/ ANN/SVM + SHAP	擁擠狀態、到院方式	美國單一急診 177,665 人次	AUROC 0.78–0.81；擁擠狀態最重要；應最小化偽陰性	單院；無公平性評估
[6] Liu et al., BMC HSR	2026	台灣門診抽血佇列長度多步預測	XGBoost/RF/Lasso vs 移動平均	服務類型、輪椅、完成數	亞東醫院院內資料	RF 最佳；ML 均優於傳統基準	預測人數非個人等待
[7] Senderovich et al., Inf. Syst.	2015	多類別服務流程延遲預測	Queue mining：排隊理論預測器 + 迴歸	多類別優先權、事件日誌	電信、金融真實日誌	大幅優於忽略排隊結構的預測器	非醫療資料
[8] Chocron et al., IEEE TEM	2022	排隊理論 vs ML 的延遲預測	排隊理論預測器 vs 多種 ML	多類別、優先權、放棄	多類別服務系統	排隊理論常與 ML 相當或更好、成本低；ML 在有高優先權類別時勝出	非醫療場域
[9] Shahbazi et al., arXiv	2026	階層醫療資料預測區間	Bayesian 階層 RF + 群組 conformal	醫院／區域階層	61,538 筆、3,793 家醫院	覆蓋 94.3%；區間窄 21%	未針對等待時間；預印本
[10] Chowa et al., AI Review	2026	LLM agent 綜述	單／多代理、工具、規劃／記憶／自省	—	108 篇、68 個基準	動態環境弱；可靠性為開放問題	綜述
[11] Hasan et al., arXiv	2026	醫療預約 LLM agent	Function calling + RAG + 確定性護欄	預約流程、緊急偵測	680 情境	91.8% 完成、96% 安全合規	預印本；無規劃描述
[17] Toffaha et al., Intell.-Based Med.	2025	病人未到預測綜述	LR、樹模型、集成、深度學習	未到行為依場域而異	52 篇（2010–2025）	最佳 AUC 0.75–0.95；缺口：系統整合、遷移學習	綜述
[18] Zhang et al., BMC HSR	2023	告知預期等待對滿意度的影響	情境實驗（非 ML）	等候心理、期望管理	眼科門診 297 情境	最接近實際最佳；±10 分仍顯著；±20 分無效	假設情境；單院單醫師

讓模型從醫師速率分佈隱性學習，於 Limitations 寫明。

C. 十個深度理解問題

Q1. (Why) 為什麼「前面還有 10 號」在 A 醫師可能是 15 分鐘、在 B 醫師可能是 1 小時？請用資料說明。

Q2. (What-if) 若醫院拿掉「已報到待看診人數」欄位，哪些預測會退化？

Q3. (Trade-off) 出門時間從 P20 改成 P10 或 P50，過號率與空等分鐘各如何變化？為何不對稱？

Q4. (Failure case) 描述一個系統會給出嚴重錯誤建議的情境（代診、API 查無資料、颱風日、停滯後連叫 5 號），Agent 如何偵測並補救？

Q5. (Evidence) 「低估等待比高估傷人」的證據是什麼？能直接套用到「幾點出門」嗎？

Q6. (Comparison) 為何不用 LSTM／Transformer 而用 LightGBM 分位數回歸？排隊式基準線有沒有可能贏？

Q7. (Design decision) 監看迴圈為何是確定性程式而非讓 LLM 決定要不要通知？

Q8. (Real-world) 下午診 12:20 出現在 API 但

13:30 才開診，一位 3 號病人 12:30 問「我幾點出門」，系統該怎麼回？

Q9. (Ethics) 怎麼證明系統對醫院伺服器的負擔「跟一個人開著網頁差不多」？醫院要求停止時怎麼處理？

Q10. (Feedback) 若 500 位病人同時使用且都照建議到院，會發生什麼？模型還準嗎？

IV. Proposed Scheme

A. 應用情境與範圍

對象為臺中榮總門診病人與家屬。**S1 掛號前查詢**：該醫師的歷史速率、停滯時段、通常幾點看完。**S2 掛號後訂閱**：給診間、午別、號碼、交通分鐘數，Agent 持續監看、預測叫號區間、在該出門時推播；可在開診前訂閱。**S3 變化提醒**：偵測代診、延誤公告、速度異常、預測大幅改變、已叫到、診次結束，重新推理並通知。不掛號、不換診、不查個人掛號資料；系統無法得知使用者是否已報到，所有提醒皆為建議，使用者可按「我到了」停止出門提醒、「已叫到」結束訂閱。

B. System Architecture

圖 1 為八個模組。① **User**：病人與家屬，介面以按鈕為主。② **Query/Input**：LINE Messaging API；Rich Menu 提供查詢、訂閱、取消；訂閱只需四欄；不要求身分證、病歷號或定位。③ **Planner & Reasoning Agent**：系統核心，是監看—推理—決策迴圈而非問答機器人：意圖解析規則優先、LLM 補位；每 60 秒重建特徵、重新預測；綜合預測區間、異常偵測、領域規則與通知策略，決定不動作／更新／通知／結束；資料不足時降級為基準線並註明。④ **Data Acquisition**：唯一即時來源是自建燈號收集器（2026-10-22 上線，GCP 免費層，自動重啟、每日備份、監控網頁），每 60 秒一次全院查詢、只存變化到 SQLite。Agent 與收集器同機直接讀資料庫，**不對醫院 API 產生額外請求**；訂閱與回饋存於獨立資料庫。輔助來源：門診手冊 PDF、停診公告、使用者自填交通時間。⑤ **Analytics Engine**：特徵為號碼差、現場人數（非 N 前方人數）、過號人數、今日滾動每號分鐘數、該醫師歷史速率、診次已進行時間、距報到截止時間、公告類別、代診旗標；基準線為號碼差 × 該醫師當日每號分鐘數，依序退回醫師歷史、同科、全院中位數；模型為 LightGBM 分位數回歸輸出 P20/P50/P80，並以今日與歷史速率比值做異常偵測。⑥ **Domain Knowledge**：叫號規則（跳號、過號插回、83 歲以上優先）、診次生命週期（下午診 12:20 起出現在系統但 13:30 才叫號、停滯集中於開診與中午、看完約 9 分鐘後消失）、停診行事曆（科別清單為空即今日無診，2026 年光復節連假實測）、公告語意（LLM few-shot 分類為請假／代診／延誤／截止，失敗退回關鍵字）。⑦ **Decision/Recommendation**：「等多久」回報 P50 附 P80 上界；「幾點出門」$=$ now $+W_{P20}-$ 交通 $-$ 緩衝；到達出門時間推播一次，之後僅在預測變動 >15 分、代診／延誤、速度異常、已叫到、診次結束時再通知，同類通知 10 分鐘冷卻。⑧ **Output & Interaction**：推播三段——結論、依據、區間；使用者回報作為真值。

C. Flowchart

圖 2：意圖解析後分流至 S1 或 S2；訂閱先檢查今日有無門診與診次是否已出現，再進入每 60 秒的監看迴圈——狀態變化時重新預測並判斷事件，每輪檢查是否到達出門時間；人機互動與例外處理（API 連續失敗、收集器當機、代診致歷史不足）列於圖下方。

D. Pseudocode

演算法 1 為 Agent 的監看迴圈，演算法 2 為預測；拆成兩層以區分「Agent 的邏輯」與「Model 的邏輯」。

E. Evaluation and Expected Outcomes

以收集器累積的真實資料做時間序列回測（前期訓練、後期測試）；真值為該診次第一筆 $cur_seq \geq N$ 的觀測時間（誤差 ≤60 秒）。基準線：(B0) 固定每號 3.2 分鐘；(B1) 號碼差 × 醫師歷史平均；(B2) 滾動平均。指標：MAE、分位數損失、P80 覆蓋率，以及面向病人的過號率（依建議出門仍晚於實際叫號的比例）、平均空等分鐘、每次訂閱通知次數。Final 階段以組員及親友進行兩週 LINE Bot 實測。預期產出：(1) 臺中榮總門診叫號時間資料集與其統計特性；(2) 在過號率與空等分鐘上優於固定規則的分位數模型，並量化醫師效應與停滯對誤差的貢獻；(3) 可實際使用的 LINE 候診代理人。本提案尚未完成實驗，以上為預期結果。

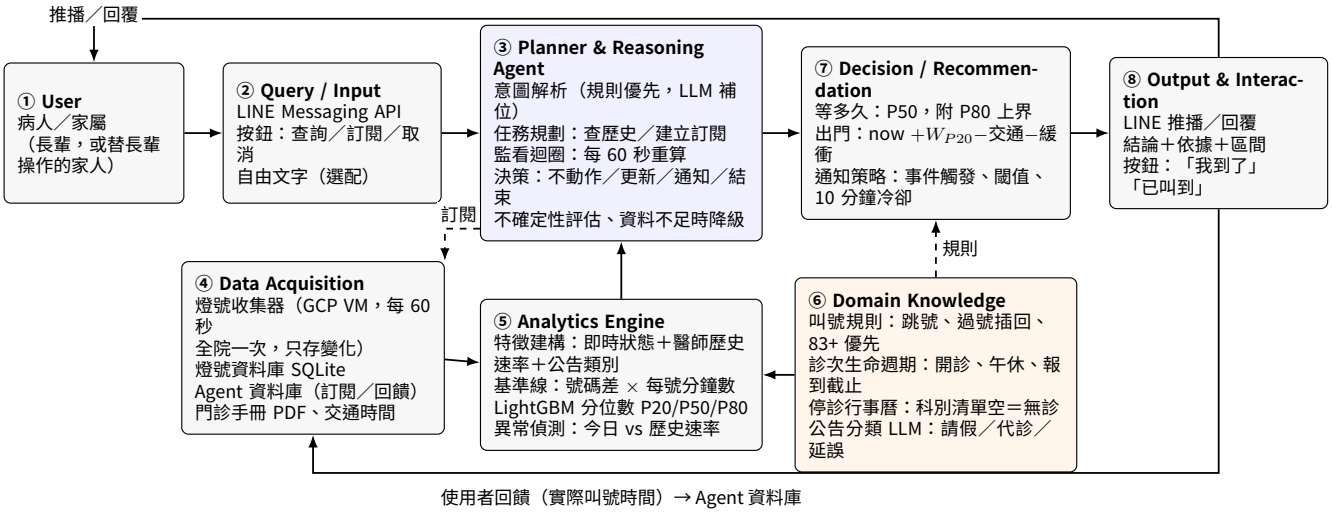


Figure 1. VGHTC Queue Agent 系統架構。實線為資料／控制流，虛線為規則與知識的注入；③ 是確定性的監看—推理—決策迴圈，LLM 只出現在意圖補位、公告分類與解釋生成。

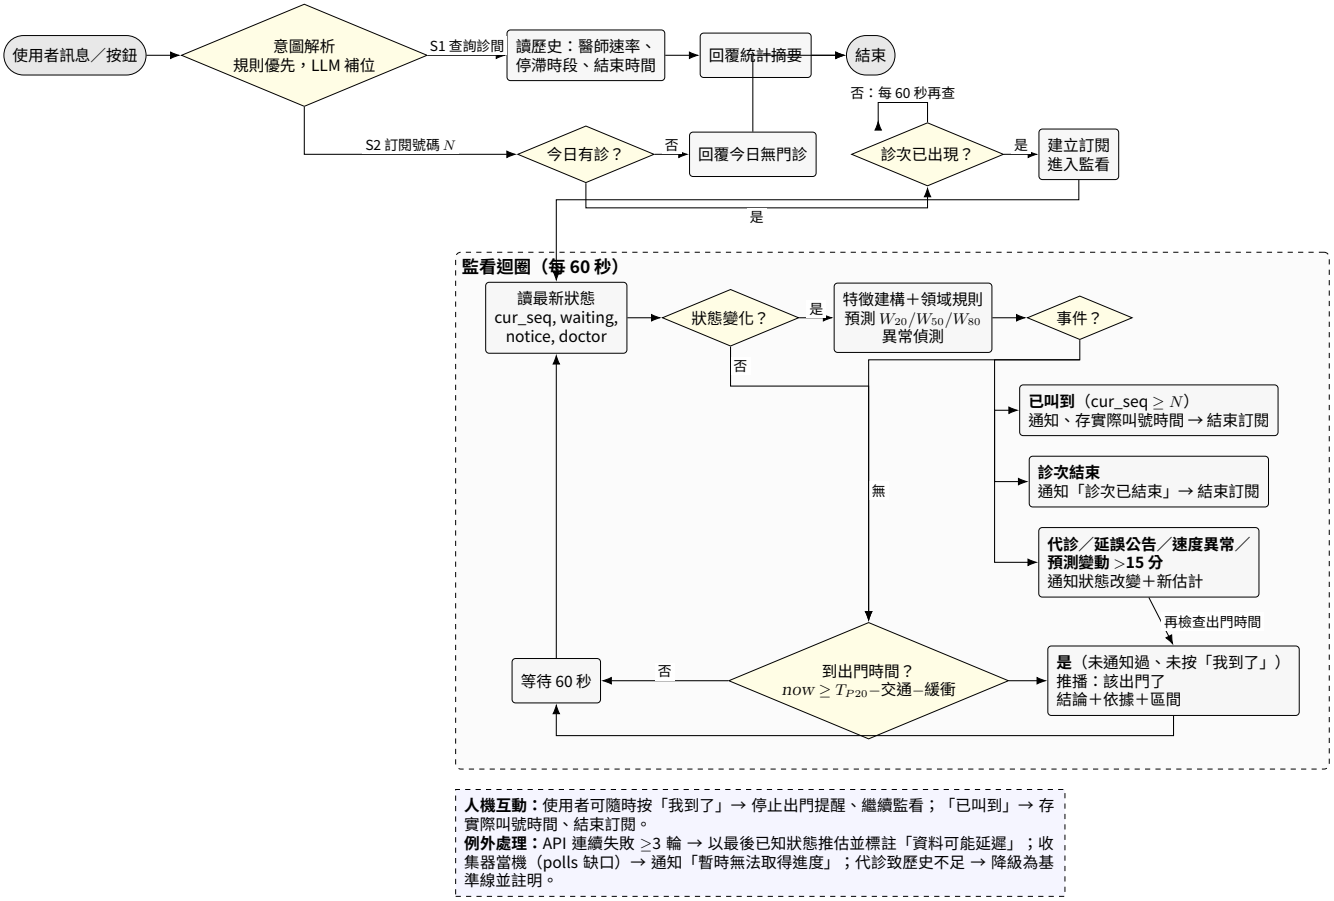


Figure 2. 訂閱與監看流程：Input → Processing → AI/Analytics → Decision → Output，含監看迴圈、事件分支、人機互動與例外處理。

F. Technical Feasibility

表 2 列出現況：資料與基礎設施已就緒，模型為 CPU 可訓練的表格模型，介面為成熟的 LINE Messaging API。

G. 資料倫理與資安

只使用無需登入的公開 API；輪詢頻率與官網自動刷新相同（60 秒），每輪一次請求，polls 表可稽核。**不使用**同頁面的「以身分證／病歷號查詢掛號」API；不蒐集身分證、病歷號、定位；訂閱結束後刪除 LINE 使用者 ID，只保留去識別化的

Algorithm 1. Queue Agent — Subscription Monitoring Loop

Input: subscription $s = (room, timeFlag, N, travelMin)$, call-light store DB
Output: notifications; ground-truth record when N is called

if DB.sectionListEmpty($today$) **then**
  notify(“今日無門診”); **return**
end if
$sess \leftarrow DB$.findSession($today, s.room, s.timeFlag$)
while $sess = \emptyset$ **do**
  sleep(60 s); re-query $sess$ ▷ 提前訂閱
end while
$arrived \leftarrow$ false; $notifiedLeave \leftarrow$ false; $lastEst \leftarrow \emptyset$
while $sess.active$ **do**
  $st \leftarrow DB$.latestState($sess$) ▷ cur_seq, waiting, passed, doctor, notice
  if $st.cur_seq \geq N$ **then**
    notify(“已叫到 N 號”); record($sess, N, st.ts$); **break**
  end if
  $x \leftarrow$ BuildFeatures($sess, st, N$) ▷ Alg. 2
  $(W_{20}, W_{50}, W_{80}) \leftarrow$ Predict(x)
  $drift \leftarrow$ rateToday($sess$)/hist.rate($sess.doctor$)
  $E \leftarrow$ DetectEvents($st, lastState, drift, W_{50}, lastEst$)
    $E \subseteq$ {doctorChanged, notice∈ {請假,代診,延誤},
    $|drift - 1| > 0.5$, $|W_{50} - lastEst| > 15$}
  if $E \neq \emptyset$ **and** cooldownOK(E) **then**
    notify(Explain($E, W_{20}, W_{50}, W_{80}, st$))
  end if
  $arrived \leftarrow arrived \vee$ user.pressed(“我到了”)
  $leaveAt \leftarrow now + W_{20} - s.travelMin - BUFFER$
  if $\neg arrived \wedge \neg notifiedLeave \wedge now \geq leaveAt$ **then**
    notify(Explain(“該出門了”, $W_{20}, W_{50}, W_{80}, st$)); $notifiedLeave \leftarrow$ true
  end if
  $lastEst \leftarrow W_{50}$; $lastState \leftarrow st$; sleep(60 s); refresh $sess$
end while
if $sess.ended \wedge st.cur_seq < N$ **then**
  notify(“診次已結束，請洽診間”)
end if

Algorithm 2. Wait-Time Estimation with Domain Features

Input: session $sess$, state st, target N, history H
Output: (W_{20}, W_{50}, W_{80}) in minutes

$gap \leftarrow N - st.cur_seq$ ▷ 號碼差
$onsite \leftarrow st.waiting$ ▷ 現場人數，非 N 前方人數
$r_{\text{today}} \leftarrow$ rollingRate($sess$, 30 min) ▷ 今日每號分鐘
$r_{\text{hist}} \leftarrow H$.rate($doctor, weekday, timeFlag, hour$)
if $r_{\text{hist}} = \emptyset$ **then**
  $r_{\text{hist}} \leftarrow H$.rate($section$); $flag \leftarrow$ fallback
end if
$elapsed \leftarrow now - sess.start$; $toBreak \leftarrow$ nextBreak($timeFlag$) $- now$
$caughtUp \leftarrow [\, st.cur_seq - st.tot_seq = 5 \,]$ ▷ 已追上最末號
$nClass \leftarrow$ ClassifyNotice($st.notice$) ▷ LLM few-shot，失敗退回關鍵字
$x \leftarrow (gap, onsite, st.passed, r_{\text{today}}, r_{\text{hist}}, r_{\text{today}}/r_{\text{hist}},$
  $elapsed, toBreak, caughtUp, nClass, doctorChanged,$
  $weekday, timeFlag, hour)$
if model.trained $\wedge$ $flag \neq$ fallback **then**
  $(W_{20}, W_{50}, W_{80}) \leftarrow$ LightGBM_quantile(x)
else
  $r \leftarrow r_{\text{today}}$ if available else r_{hist}; $W_{50} \leftarrow gap \cdot r$; $W_{20} \leftarrow 0.7W_{50}$; $W_{80} \leftarrow 1.5W_{50}$ ▷ baseline
end if
return (W_{20}, W_{50}, W_{80})

（診間、號碼、預測、實際叫號時間）。收集器主機不開對外連接埠，SSH 僅經 IAP，監控網頁以 Google 登入保護；公告文字送交 LLM 前不含個資。若要對外公開服務，先徵詢醫院資訊室。

References

[1] S. Ang, S. Kwasnick, M. Bayati, E. Plambeck, and M. Aratow, “Accurate emergency department wait time prediction,” *Manufacturing & Service Operations Management*, vol. 18, no. 1, pp. 141–156, 2016.

[2] A. Pak, B. Gannon, and A. Staib, “Predicting waiting time to treatment for emergency department patients,” *Int. J. Medical Informatics*, vol. 145, 104303, 2021.

[3] J. Shin, D. A. Lee, J. Kim, C. Lim, B.-K. Choi, *et al.*, “Dissatisfaction-considered waiting time prediction for outpatients with interpretable machine learning,” *Health Care Management Science*, vol. 27, no. 3, pp. 370–390, 2024.

[4] L. L. Guo, R. Tang, J. Y. Wang, *et al.*, “Predicting waiting times for medical tasks in a pediatric hospital using machine learning: Comprehensive, retrospective, real-world study,” *JMIR Medical Informatics*, vol. 13, e77297, 2025.

[5] H. Wang, N. Sambamoorthi, D. Sandlin, and U. Sambamoorthi, “Interpretable machine learning models for prolonged emergency department wait time prediction,” *BMC Health Services Research*, vol. 25, 403, 2025.

[6] T.-C. Liu, M.-S. Chen, Y.-C. Lee, C.-T. Yang, and C.-J. Lu, “Developing machine learning multistep ahead forecasting scheme to predict outpatient queue length in phlebotomy department,”

Table 2. 技術可行性

項目	狀態
資料來源	醫院公開 JSON API；欄位意義已以 5 小時 5,310 筆驗證
收集器	2026-10-22 上線，GCP 免費層，自動重啟、每日備份、監控網頁
累積資料	2 個門診日：259 診次、9,924 筆變化；每日約新增 4–6 千筆
模型	LightGBM 分位數回歸，CPU 可訓練
介面	LINE Messaging API（免費方案每月推播 200 則，demo 足夠）
LLM	僅公告分類與解釋生成，呼叫短、可快取
風險	醫院 API 改版（有失敗記錄與告警）；GCP 試用 2026-12-20 到期前須啟用完整帳戶

BMC Health Services Research, 2026, doi:10.1186/s12913-026-15327-y.

[7] A. Senderovich, M. Weidlich, A. Gal, and A. Mandelbaum, "Queue mining for delay prediction in multi-class service processes," *Information Systems*, vol. 53, pp. 278–295, 2015.

[8] E. Chocron, I. Cohen, and P. Feigin, "Delay prediction for managing multiclass service systems: An investigation of queueing theory and machine learning approaches," *IEEE Trans. Engineering Management*, 2022 (accepted).

[9] M. A. Shahbazi, A. Baheri, and N. Azadeh-Fard, "Adaptive conformal prediction via Bayesian uncertainty weighting for hierarchical healthcare data," arXiv:2601.01223, Jan. 2026.

[10] S. S. Chowa, R. Alvi, S. S. Rahman, *et al.*, "From language to action: A review of large language models as autonomous agents and tool users," *Artificial Intelligence Review*, vol. 59, 71, 2026.

[11] H. Hasan, S. Salman, A. T. Abou Dargham, A. Mohanna, and A. Chehab, "Toward trustworthy large language model agents in healthcare," arXiv:2607.05055, Jul. 2026.

[12] 衛生福利部中央健康保險署，「2025 年國人平均每人門診就醫次數前二十大疾病」，全民健康保險統計，產製日期 2026-09-01（全國合計 16.32 次／人）。https:// www.nhi.gov.tw/ ch/ cp-6015-0907b-3023-1.html

[13] 內政部統計處，「02-01 人口年齡分配按單齡」，2025 年底（65 歲以上 4,673,155 人，占總人口 23,299,132 人之 20.06%）。https:// statis.moi.gov.tw/ micst/ webMain.aspx?k=menuy

[14] 臺北榮民總醫院，《便民手冊》第壹章門診服務，114.04.01 更新，第 11 頁。

[15] 臺中榮民總醫院，門診看診進度診間公告（皮膚科 2525–2527 診，2026-10-22 觀測）。https://www.vghtc.gov.tw/OutpatientProcess/5986

[16] 臺中榮民總醫院，網路預約掛號說明。https://register.vghtc.gov.tw/register/regDesc.jsp

[17] K. Toffaha, M. C. E. Simsekler, M. A. Omar, and I. ElKebbi, "Predicting patient no-shows using machine learning: A comprehensive review and future research agenda," *Intelligence-Based Medicine*, vol. 11, 100229, 2025.

[18] H. Zhang, W.-M. Ma, J.-J. Zhu, *et al.*, "How to adjust the expected waiting time to improve patient's satisfaction?" *BMC Health Services Research*, vol. 23, 455, 2023.

[19] 臺中榮民總醫院行動服務 App，App Store，V2.6.6。

[20] 臺北榮總行動就醫服務 App，App Store。

[21] 全能掛號王 SeeDoctor，App Store。

[22] 工商時報，「門診小幫手 LINE 診號查詢與通知服務平台」，2020-11-25。

[23] 看診進度助手，App Store。

[24] J. D. C. Little, "A proof for the queuing formula: $L = \lambda W$," *Operations Research*, vol. 9, no. 3, pp. 383–387, 1961.

[25] W. J. Hopp and M. L. Spearman, *Factory Physics*, 3rd ed. Waveland Press, 2011.

[26] D. R. Cox and W. L. Smith, *Queues*. Methuen, 1961.